

Poboljšavanje OOD generalizacije neuralnog algoritamskog rezonovanja za BFS i Dijkstra algoritme korišćenjem Pointer Graph Network arhitekture i "Grokking" režima treniranja

Marko Milenković
Broj indeksa: RA60/2023

28. maj 2026.

1. Definicija problema i pregled projekta

Modeli za neuralno algoritamsko rezonovanje (NAR) suočavaju se sa izazovima pri "out-of-distribution"(OOD) generalizaciji, gubeći preciznost pri prelasku sa malih grafova na masivne topologije [1]. Standardne grafovske neuronske mreže su sposobne za interpolaciju na malim grafovima, ali ne uspeavaju da zadrže tačnost pri skaliranju. Ovaj projekat ima za cilj rešavanje navedenog problema težnjom ka striktnom usvajanju opšte algoritamske logike, umesto lokalnog memorisanja. Primenom Pointer Graph Network (PGN) arhitekture na SALSA-CLRS benchmark-u, model će biti obučavan na malim sintetičkim grafovima ($N \leq 16$), a evaluiran na drastično većim i strukturno drugačijim topologijama ($N = 1600$). Da bi se sprečilo slabljenje skrivenih stanja tokom dugačkih sekvenci izvršavanja, u arhitekturu se dodaje GRU memorija. Kako bi se isprovocirao fenomen "grokking-a" i osigurala robusna OOD generalizacija, biće implementirana jako regularizovana linija obučavanja koja uključuje injektovanje Gausovog šuma u skriveno stanje, agresivno opadanje težina i velik batch size.

2. Uvod i motivacija

Kao što su pokazali standardizovani benchmark skupovi poput CLRS-30 [1] i noviji SALSA-CLRS [2], ključni izazov u modelovanju algoritama nije interpolacija na podacima sličnim onima iz skupa za treniranje, već sposobnost ekstremne "out-of-distribution"(OOD) generalizacije. Klasičan algoritam koji pronalazi najkraći put na

16 čvorova jednako uspešno i precizno radi i na grafovima sa nekoliko redova veličine više čvorova. Ukoliko neuronska mreža doživi pad performansi pri promeni skale, što je čest slučaj pri prelasku na masivne topologije kakve SALSA-CLRS evaluira, to ukazuje da model nije usvojio univerzalnu algoritamsku logiku, već je samo zapamtio lokalne heuristike. Zbog toga je postizanje stabilne OOD generalizacije ultimativni dokaz striktnog algoritamskog usklađivanja (algorithmic alignment). Uspešno rešavanje ovog problema nosi izuzetan društveni značaj i široku mogućnost praktične primene, što je detaljnije obrazloženo u **Dodatku C**.

Do sada, mnogi pristupi rešavanju ovog problema oslanjali su se prevashodno na uvođenje novih, visoko kompleksnih arhitektura. Na primer, noviji modeli poput FloydNet-a [5] postižu izuzetnu generalizaciju na širokom spektru algoritama uvođenjem globalnog tenzora relacija inspirisanog dinamičkim programiranjem. Međutim, ovakva arhitektonska rešenja sa sobom nose ogromnu računsku i memorijsku kompleksnost (npr. $\mathcal{O}(N^3)$), što ih čini teško primenjivim i neskalabilnim na masivnim, retkim (sparse) grafovima kakvi se sreću u realnim primenama.

Nasuprot tome, ovaj projekat je motivisan idejom da se ključ za robusnu i skalabilnu OOD generalizaciju ne nalazi nužno u kreiranju sve složenijih arhitektura, već u samom *režimu obučavanja* (optimizaciji). Fokusiranjem na tehnike regularizacije na postojećoj, lakšoj arhitekturi kao što je Pointer Graph Network (PGN) — poput uvođenja šuma, strogog opadanja težina (weight decay) i masivnih serija obrade (large batch sizes) — cilj je isprovocirati fenomen "grokking-a"[4]. Na ovaj način, model se primorava da usvoji striktnu algoritamsku logiku, dokazujući da optimizacione promene u liniji obučavanja mogu osigurati vrhunsku skalabilnost bez žrtvovanja računarske efikasnosti.

3. Skup podataka

Kao osnova će se koristiti **SALSA-CLRS benchmark**, koji pruža mehanizme za generisanje sintetičkih grafova proizvoljnih osobina i specifično je dizajniran za testiranje skalabilnosti algoritamskog rezonovanja na masivnim mrežama [2]. Modeli će se trenirati isključivo na sintetički generisanim malim Erdős-Rényi (ER) grafovima ograničenim na $N \leq 16$ čvorova, sa 50.000 grafova u skupu za treniranje (vizuelni primeri sintetičkih grafova i očekivanog izlaza nalaze se u **Dodatku A**). Evaluacija će se vršiti na drastično većim grafovima, sve do $N = 1600$ čvorova, koji uključuju strukturno drugačije topologije poput Delaunay trijangulacija i Watts-Strogatz (WS) mreža kako bi se evaluirala OOD generalizacija.

- **Link do skupa podataka:** <https://github.com/johannesminder/SALSA-CLRS>
- **Ciljna obeležja (Target):** S obzirom na to da rešavamo probleme obilaska grafa (BFS) i najkraćeg puta (Dijkstra), konačni izlazni podaci na nivou čvora su vrednosti "pokazivača" (predecessor pointers) koji rekonstruišu stablo pretrage, odnosno stablo najkraćih puteva. U slučaju Dijkstrinog algoritma, izlaz dodatno uključuje i predviđene distance. Pored konačnog izlaza, ciljna obeležja obuhvataju i "nagoveštaje" (hints) - istoriju međukoraka izvršavanja algoritma. Ovi nagoveštaji će se koristiti u funkciji gubitka (loss) kako bi obezbedili guste, korak-po-korak gradijente neophodne za striktno učenje algoritamske logike.

4. Metodologija

Cilj projekta je uvođenje i optimizacija jako regularizovane linije obučavanja (training pipeline) za Pointer Graph Networks (PGN) [3] na zadacima BFS i Dijkstra, izbegavajući pritom potrebu za kreiranjem potpuno novih arhitektura. Da bi se model usmerio ka usvajanju opšte algoritamske logike umesto memorisanja, biće primenjene sledeće tehnike:

- **Arhitektonska proširenja:** Integracija Gated Recurrent Unit (GRU) memorije nakon pointer graph network-a radi sprečavanja slabljenja skrivenih stanja tokom dugačkih sekvenci izvršavanja.
- **Regularizacija šumom:** Injektovanje Gausovog šuma u skrivena stanja tokom treniranja kako bi model naučio da samostalno koriguje mikroskopske greške tokom rollout-a.
- **Optimizacija:**
 - Korišćenje mešavine autoregresivnog (AR) učenja i "Teacher Forcing-a".
 - Modeli će biti trenirani sa agresivnim opadanjem težina (npr. $\lambda = 0.09$) korišćenjem AdamW optimizatora kako bi se isprovocirao "grokking" fenomen [4].
 - Treniranje će se vršiti sa izuzetno velikom batch size-om (npr. $\mathcal{B} = 2048$) radi smanjenja varijanse gradijenta i boljeg iskorišćenja paralelizacije.

5. Način evaluacije

Performanse će biti evaluirane upoređivanjem našeg optimizovanog modela sa standardnim SALSA-CLRS PGN osnovnim (baseline) modelom (referentne vrednosti iz originalnog rada nalaze se u **Dodatku B**). Pratiće se sledeće metrike:

- **Striktna tačnost grafa (Graph Accuracy):** Najstroža metrika koja zahteva da celokupno stablo pretrage/najkraćih puteva na nivou celog grafa bude besprekorno predviđeno.
- **Tačnost čvorova (Node Accuracy):** Lokalna metrika koja meri procenat tačno usmerenih pokazivača pojedinačnih čvorova.

6. Tehnologije i hardver

- **Programski jezik:** Python.
- **Okviri za duboko učenje:** PyTorch.
- **Biblioteke za GNN:** PyTorch Geometric (PyG).
- **Praćenje eksperimenata:** Weights & Biases (W&B).
- **Hardver:** Nvidia RTX 5090 grafička kartica ili (ukoliko bude omogućen pristup) resursi državnog data centra u Kragujevcu.

7. Primeri


- **The CLRS Algorithmic Reasoning Benchmark:** <https://github.com/google-deepmind/clrs>
- **SALSA-CLRS Benchmark:** <https://github.com/johannesminder/SALSA-CLRS>

8. Relevantna literatura


Literatura

- [1] Veličković, P., et al. (2022). The CLRS Algorithmic Reasoning Benchmark. U *Proceedings of the 39th International Conference on Machine Learning (ICML)*.
- [2] Minder, J., Grötschla, F., Mathys, J., & Wattenhofer, R. (2023). SALSA-CLRS: A Sparse and Scalable Benchmark for Algorithmic Reasoning. U *2nd Learning on Graphs Conference (LoG)*.
- [3] Veličković, P., Buesing, L., Overlan, M., Pascanu, R., Vinyals, O., & Blundell, C. (2020). Pointer Graph Networks. *Advances in Neural Information Processing Systems (NeurIPS)*.
- [4] Power, A., Burda, Y., Edwards, H., Babuschkin, I., & Misra, V. (2022). Grokking: Generalization Beyond Overfitting on Small Algorithmic Datasets. *arXiv preprint arXiv:2201.02177*.
- [5] Yu, J., Zeng, M., & Ye, Q. (2026). FloydNet: A Learning Paradigm for Global Relational Reasoning. *arXiv preprint arXiv:2601.19094*.

A Dodatak A: Vizuelni primeri skupa podataka



Slika 1: Primeri sintetičkih Erdős-Rényi (ER) grafova generisanih za potrebe obučavanja i evaluacije.



Slika 2: Primer izlaza Dijkstrinog algoritma. Crveni čvor predstavlja polazni čvor (izvor), a crvene ivice usmereno stablo najkraćih puteva (shortest path tree).

B Dodatak B: Referentni (Baseline) rezultati

U Tabeli 1 prikazani su zvanični SALSA-CLRS rezultati za arhitekturu Pointer Graph Network obučavanu sa nagoveštajima (PGN (H)). Kao što se može primetiti, model uspešno vrši interpolaciju na grafovima iste veličine kao u skupu za treniranje ($N = 16$), ali doživljava značajan pad tačnosti pri skaliranju na veće grafove i neviđene topologije (WS i Delaunay), posebno kod složenijih problema poput Dijkstrinog algoritma.

Topologija	Broj čvorova	BFS: PGN (H) [%]	Dijkstra: PGN (H) [%]
ER	16	100.0 ± 0.0	99.3 ± 0.1
	80	99.8 ± 0.1	94.2 ± 2.5
	160	99.6 ± 0.1	92.0 ± 2.3
	800	98.7 ± 0.3	87.1 ± 2.7
	1600	98.5 ± 0.3	84.5 ± 3.4
WS	16	100.0 ± 0.0	97.8 ± 0.2
	80	96.1 ± 0.5	85.8 ± 6.0
	160	90.8 ± 0.8	80.9 ± 7.0
	800	76.4 ± 1.6	60.5 ± 8.3
	1600	80.6 ± 1.0	52.4 ± 8.3
Delaunay	16	100.0 ± 0.0	99.2 ± 0.1
	80	97.5 ± 0.8	84.9 ± 6.8
	160	89.4 ± 1.6	72.8 ± 8.9
	800	53.2 ± 2.4	50.8 ± 4.6
	1600	40.8 ± 3.2	46.4 ± 3.1

Tabela 1: Lokalna tačnost čvorova (Node Accuracy) izražena u procentima. Prikazane su isključivo PGN (sa korišćenjem hintova) kolone iz originalnog SALSA-CLRS rada za BFS i Dijkstrin algoritam.

Istraživačka hipoteza: Preliminarni rezultati ovog istraživanja sugerišu da je moguće postići tačnost od preko 99% na svim veličinama i topologijama grafova za BFS algoritam, isključivo primenom predloženog optimizacionog "grokking" režima treniranja i arhitekture. S obzirom na to da je BFS specijalan (relaksiran) slučaj Dijkstrinog algoritma (Dijkstra na grafu sa jednakim težinama grana), pretpostavljamo da se predložena regularizovana linija obučavanja i arhitektura mogu direktno prilagoditi kako bi se prevazišao pad performansi i drastično nadmašili prikazani referentni rezultati i za Dijkstrin algoritam.

C Dodatak C: Društveni značaj i praktična primena

Neuralno algoritamsko rezonovanje teži da omogući neuronskim mrežama donošenje logički tačnih odluka nad sirovim i neuređenim podacima iz stvarnog sveta. Uspešno rešavanje problema skalabilnosti i OOD generalizacije za algoritme na grafovima, poput pretrage u širinu (BFS) i pronalaska najkraćeg puta (Dijkstra), prevazilazi okvire akademskog izazova i nosi veliku praktičnu vrednost.

Zadržavanje tačnosti ovih modela na masivnim mrežama omogućava njihovu pouzdanu implementaciju u različitim realnim sistemima ogromnih razmera. Primeri takvih domena primene obuhvataju:

- **Globalne telekomunikacione mreže:** Optimizacija rutiranja saobraćaja u realnom vremenu unutar kompleksnih topologija, gde su ruteri čvorovi mreže, a veze podložne šumu, opterećenju ili ispadima.
- **Transport, navigacija i logistika:** Dinamičko usmeravanje vozila u modernim "pametnim" gradovima koje računa ne samo udaljenost, već direktno uči iz kontinualnih podataka sa senzora o gužvama i nepredviđenim zastoјima u saobraćaju.
- **Analiza velikih društvenih i bioloških mreža:** Efikasno procesiranje masivnih grafova koji nastaju u medicinskim istraživanjima (npr. interakcije proteina) ili prilikom prevencije prevara pretragom mreža finansijskih transakcija.

Ostvarivanjem striktnog algoritamskog usklađivanja, otvara se put ka kreiranju bezbednijih, pametnijih i adaptivnijih infrastrukturnih sistema koji smanjuju potrošnju resursa, unapređuju energetska efikasnost i olakšavaju svakodnevni život.